

快时尚行业线上零售数据分析报告--postgresql

2016-2018的国内零售数据

从用户，产品，地域等多个角度探索跨境电商转内销的可能性

研究疫情期间作为国内最大跨境电商，如何实现自救？

数据来源:

shein 国内市场2016-2018年线上零售数据集 (已脱敏)

数据清洗:

需要先理解一下数据（英文），对应数据字典

第一张是注册用户表：customer

用户名称可能是空集

主键：id(用户ID，唯一的，每个用户只有一个！注册时生成)

full name 可能有空值! 还可能重复!

注册日期：重复，有空值，不唯一

	A	B	C	D	E	F	G	H	I	J
1	注册用户表: customers									
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认		
3	id	用户ID	VARCHAR(15)	Y	Y	Y	N	N		
4	full_name	用户名称	VARCHAR(20)	N	N	N	N	N		
5	created_at	注册日期	INT	N	N	N	N	N		
6										
7										
8										
9	2016-08-16到2018-03-22注册用户数44661人。									
10										

第二张表：访问记录表login_log

每一个用户的单日访问记录，标识ID没有实际业务意义

同一个用户在某一天只会记录一次

主键: id,这个id只是为了识别标记的,没意义

customer_id:这是用户id,和第一张表中的用户id代表值一样! 每个用户唯一的id;用户ID可能会重复

但是一天之內一个用户id只会被标记一次!

	A	B	C	D	E	F	G	H	I	J
1	访问记录表: login_log									
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认		
3	id	标识ID	VARCHAR(5)	Y	Y	Y	N	N		
4	customer_id	用户ID	VARCHAR(15)	N	N	N	N	N		
5	logion_date	访问日期	DATE	N	N	N	N	N		
6										
7										
8	2018/3/1到2018-03-22共270位用户的915次访问记录。									
9										

第三张表：每一笔订单记录

主键是订单id，无重复！目前第一次出现
下单，关闭，取消日期详细描述了该订单从第一次下单开始的状态！ 下单-->未支付--->支付或者取消---->关闭
用户id:对应前面表格:每一个用户都应该有一个代表账号的id
国家，省份，城市，区县，地址：基本信息，可重复；这里用的是数字编号！
financial_status :财务状态：有五种状态
完成状态：这笔订单在审核日期的三个状态

	A	B	C	D	E	F	G	H	I
1	订单主表: orders								
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认	
3	id	订单ID	VARCHAR(15)	Y	Y	Y	N	N	
4	created_at	下单日期	DATE	N	N	N	N	N	
5	closed_at	关闭日期	DATE	N	N	N	N	N	
6	cancelled_at	取消日期	DATE	N	N	N	N	N	
7	customer_id	用户ID	VARCHAR(15)	N	N	N	N	N	
8	country	国家	CHAR	N	N	N	N	N	
9	province	省份	VARCHAR(4)	N	N	N	N	N	
10	city	城市	VARCHAR(4)	N	N	N	N	N	
11	district	区县	VARCHAR(4)	N	N	N	N	N	
12	address	地址	VARCHAR(100)	N	N	N	N	N	
13	financial_status	财务状态 (paid已支付, refunded已退回, partially_refunded部分退回, pending待定, voided无效)	VARCHAR(20)	N	N	N	N	N	
14	fulfillment_status	完成状态 (fulfilled已完成, partial部分完成, restocked已退回)	VARCHAR(10)	N	N	N	N	N	
15	processed_at	审核日期	DATE	N	N	N	N	N	
16	total_price	订单金额 (包含服务费、进口税、用券金额等)	DECIMAL(6,2)	N	N	N	N	N	
17	shipping_rate	运费	DECIMAL(6,2)	N	N	N	N	N	
18	subtotal_price	折扣后商品金额	DECIMAL(6,2)	N	N	N	N	N	
19	total_discounts	折扣金额	DECIMAL(6,2)	N	N	N	N	N	
20	total_line_items_price	商品金额	DECIMAL(6,2)	N	N	N	N	N	
21									
22									
23									
24	2016-08-21到2018-03-22有14935位用户下了21358笔订单，共计1607113元，其中410笔订单被取消。								
25									
26									
27									

第四张表：订单详情表

id:主键，为单品
order_id 对应订单id;一个订单里面可能有诸多单品
商品风格？
商品id:不唯一，一个商品对应多个单品
完成状态：单品对应的订单的完成状态

	A	B	C	D	E	F	G	H	I	J	K	L
1	订单详情表: orders_items											
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认				
3	id	单品ID	VARCHAR(15)	Y	Y	Y	N	N				
4	order_id	订单ID	VARCHAR(15)	N	N	N	N	N				
5	product_style	商品风格	VARCHAR(50)	N	N	N	N	N				
6	variant_id	商品ID	VARCHAR(15)	N	N	N	N	N				
7	fulfillment_status	完成状态 (fulfilled已完成, partial部分完成)	VARCHAR(10)	N	N	N	N	N				
8	price	单价	DECIMAL(6,2)	N	N	N	N	N				
9	quantity	数量	INT	N	N	N	N	N				
10												
11												
12												
13	21360笔订单中有1275种商品36826个单品，总销量37089，商品总金额1597439元。											
14												
15												

一共记录了3万多个单品

第五张表：区域表

地址id:主键，介绍每一个地址
父级id，与区域名称并非一一对应（上一级）

区域类别：说明该地址是什么级别！

	A	B	C	D	E	F	G	H	I
1	区域表: regioninfo								
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认	
3	regionid	地址ID	VARCHAR(4)	Y	Y	N	N	N	
4	parentid	父级ID	VARCHAR(4)	N	Y	N	N	N	
5	regionname	区域名称	VARCHAR(20)	N	Y	N	N	N	
6	regiontype	区域类别 (0国家/1省份/2城市/3区县)	CHAR	N	Y	N	N	N	
7									
8									
9									
10	共有3415个区域								
11									

第六张表：产品主表

主键：产品id;第一次出现

不同产品可能会有相同名称

产品类别：同一类别有多种产品

	A	B	C	D	E	F	G	H	I
1	商品主表: products								
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认	
3	id	产品ID	VARCHAR(15)	Y	Y	Y	N	N	
4	title	产品名称	VARCHAR(50)	N	N	N	N	N	
5	product_type	产品类别	VARCHAR(10)	N	N	N	N	N	
6	created_at	建档日期	DATE	N	N	N	N	N	
7	published_at	上架日期	DATE	N	N	N	N	N	
8									
9									
10									
11									
12	2016-08-18到2018-03-15共上架了29个品类247款产品。								

第七张表：商品详情表

商品id为主键

同一产品对应多个商品


	A	B	C	D	E	F	G	H
1	商品详情表: products_skus							
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认
3	id	商品ID	VARCHAR(15)	Y	Y	Y	N	N
4	product_id	产品ID	VARCHAR(15)	N	N	N	N	N
5	product_style	商品风格	VARCHAR(50)	N	N	N	N	N
6	sku	商品名称	VARCHAR(50)	N	N	N	N	N
7	created_at	上架日期	DATE	N	N	N	N	N
8	price	单价	DECIMAL(6,2)	N	N	N	N	N
9								
10								
11								
12	247款产品中1356种商品。							
13								

一共七张表，理解一下商品，产品，单品之间区别


例如：华为手机-->华为mate30（产品）--->多个商品（套装）--->单品（颜色，内存，尺码）

每个单品ID不同（订单当中自然产生）

梳理一下表之间的关系：ER关系！



梳理一下是1对多，多对1还是多对多



导入数据

把数据导入到数据库里面

利用已经有现成的csv文件

导入到本地数据库--postgres里面

第一张表：customer

```
create table customers(  
    id varchar(15) primary key,  
    full_name varchar(30),  
    created_at int  
);
```

导入：

```
C:\Users\35473>psql -U postgres -d shein
用户 postgres 的口令：

psql (18.3)
输入 "help" 来获取帮助信息。

shein=# copy customers FROM 'D:/Users/35473/Desktop/postgredata/customers.csv' DELIMITER ',' CSV HEADER;
COPY 44661
shein=#
```

第二张表：login_log

```
create table login_log(
    id varchar(5) primary key,
    customer_id varchar(15),
    login_date date
);
```

导入数据：

```
copy login_log FROM 'D:/Users/35473/Desktop/postgredata/login_log.csv' DELIMITER ',
---copy 915
```

第三张表：orders

```
create table orders(
    id varchar(15) primary key,
    created_at date,
    closed_at date,
    cancelled_at date,
    customer_id varchar(15),
    country char,
    province varchar(4),
    city varchar(4),
    district varchar(50),
    address varchar(100),
    financial_status varchar(20),
    fulfillment_status varchar(10),
    processed_at date,
    total_price decimal(6,2),
    shipping_rate decimal(6,2),
    subtotal_price decimal(6,2),
    total_discounts decimal(6,2),
    total_line_items_price decimal(6,2)
);
```

这个表格中的数据出现了致命问题：

原excel文件里包含中文字符！

而且是未显示完全的！并且csv文件编码也不正确

```
copy orders FROM 'D:/Users/35473/Desktop/postgredata/orders.csv' DELIMITER ',' CSV HEADER;
```

```
shein=# copy orders FROM 'D:/Users/35473/Desktop/postgredata/orders.csv' DELIMITER ',' CSV HEADER NULL '\N';
COPY 21358
shein=#
```

第四张表：order_items

```
create table orders_items(
    id varchar(15) primary key,
    order_id varchar(15),
    product_style varchar(50),
    variant_id varchar(15),
    fulfillment_status varchar(10),
    price decimal(6,2),
    quantity int
);
```

导入数据：

```
copy orders_items FROM 'D:/Users/35473/Desktop/postgredata/orders_items.csv' DELIMITER ',' CSV HEADER;

---36826
```

第五张表：products

```
create table products(
    id varchar(15) primary key,
    title varchar(50),
    product_type varchar(15),
    created_at date,
    published_at date
);
```

```
copy products FROM 'D:/Users/35473/Desktop/postgredata/products.csv' DELIMITER ',' CSV HEADER;
```

出现问题！

```
shein=# copy products FROM 'D:/Users/35473/Desktop/postgredata/products.csv' DELIMITER ',' CSV HEADER;
ERROR:  invalid input syntax for type date: "\N"
背景： COPY products, line 6, column published_at: "\N"
shein=#
```

\N在postgre里面是空值，但在csv文件里是普通字符

我们需要告诉postgre:遇到\N就转换为null

```
COPY products
FROM 'D:/Users/35473/Desktop/postgredata/products.csv'
DELIMITER ','
CSV HEADER
```

```
NULL '\N';
```

```
---247
```

第六张表：products_skus

```
create table products_skus(  
    id varchar(15) primary key,  
    product_id varchar(15),  
    product_style varchar(50),  
    sku varchar(50),  
    created_at date,  
    price decimal(6,2)  
);
```

```
copy products_skus FROM 'D:/Users/35473/Desktop/postgredata/products_skus.csv' DELIMITER ','
```

```
---1356
```

第七张表：regioninfo

```
create table regioninfo(  
    regionid varchar(4) primary key,  
    parentid varchar(4),  
    regionname varchar(20),  
    regiontype char  
);
```

```
copy regioninfo FROM 'D:/Users/35473/Desktop/postgredata/regioninfo.csv' DELIMITER ','  
CSV HEADER ;
```

出现错误！

```
shein=# copy regioninfo FROM 'D:/Users/35473/Desktop/postgredata/regioninfo.csv' DELIMITER ',' CSV HEADER;  
ERROR: character with byte sequence 0xad 0xa5 in encoding "GBK" has no equivalent in encoding "UTF8"  
背景: COPY regioninfo, line 2  
shein=#
```

一共3415

```
shein=# SET client_encoding = 'UTF8';  
SET  
shein=# COPY regioninfo FROM 'D:/Users/35473/Desktop/postgredata/regioninfo.csv' DELIMITER ',' CSV HEADER;  
COPY 3415
```

先把这该死的postgre的默认编码转换为utf8;我真的服了，pgadmin4里面明明显示默认就是utf8，但是人家用的偏偏是GBK！

依次查看数据

```
select *
from customers;
select *
from login_log;
select *
from orders;
select *
from orders_items;
select *
from products;
select *
from products_skus;
select *
from regioninfo;
```

检查缺失值，异常值

每一个表都有主键约束，其不可能存在重复
但是会有空值，但属于正常
这些数据都是经过审核数据，是没有异常值的

需要把customers表中的时间戳转换为日期格式，并保存到新列

	id [PK] character varying (15)	full_name character varying (30)	created_at integer
1	1000206374397	Kristina Jones	1519142400
2	1000306775549	Cheryl Garrett	1519142400

可以将时间戳（integer）转换为timestamp类型，然后date转换

```
alter table customers add column created_new date;
UPDATE customers SET created_new = to_timestamp(created_at)::date;
```

	id [PK] character varying (15)	full_name character varying (30)	created_at integer	created_new date
1	221302461949	\N	1478966400	2016-11-13
2	229077292541	\N	1479312000	2016-11-17
3	229297591805	Brian Cruz	1479312000	2016-11-17

数据分析

地域分析

 判断shein的主要销售地区，用以各分地分析

分析一下shein的地域销售情况
shein国内市场主要集中能够在华南，华中，华东地区
各省市的消费金额
省份、城市、消费金额、消费金额占比
消费金额占比=各地区消费金融/总金额

- 观察表：orders

A	B	C	D	E	F	G	H	I	J	K
1	订单主表: orders									
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认		
3	id	订单ID	VARCHAR(15)	Y	Y	Y	N	N		
4	created_at	下单日期	DATE	N	N	N	N	N		
5	closed_at	关闭日期	DATE	N	N	N	N	N		
6	cancelled_at	取消日期	DATE	N	N	N	N	N		
7	customer_id	用户ID	VARCHAR(15)	N	N	N	N	N		
8	country	国家	CHAR	N	N	N	N	N		
9	province	省份	VARCHAR(4)	N	N	N	N	N		
10	city	城市	VARCHAR(4)	N	N	N	N	N		
11	district	区县	VARCHAR(4)	N	N	N	N	N		
12	address	地址	VARCHAR(100)	N	N	N	N	N		
13	financial_status	财务状态 (paid已支付, refunded已退回, partially refunded部分退回, pending待定, voided无效)	VARCHAR(20)	N	N	N	N	N		
14	fulfillment_status	完成状态 (fulfilled已完成, partial部分完成, restocked已退回)	VARCHAR(10)	N	N	N	N	N		
15	processed_at	审核日期	DATE	N	N	N	N	N		
16	total_price	订单金额 (包含服务费、进口税、用券金额等)	DECIMAL(6,2)	N	N	N	N	N		
17	shipping_rate	运费	DECIMAL(6,2)	N	N	N	N	N		
18	subtotal_price	折扣后商品金额	DECIMAL(6,2)	N	N	N	N	N		
19	total_discounts	折扣金额	DECIMAL(6,2)	N	N	N	N	N		
20	total_line_items_price	商品金额	DECIMAL(6,2)	N	N	N	N	N		
21										
22										
23										
24										
25	2016-08-21到2018-03-22有14935位用户下了21358笔订单，共计1807113元，其中410笔订单被取消。									

每一笔订单对应国家，省，市，县，
但是关于每笔订单消费金额需要怎么算呢？
一笔订单没成就是0元！成了以后这笔订单赚钱=total_price？

- 省，市怎么对应呢？
以省，市（可重复）对应每一个订单？ 订单最后实际金额？
最后按照省，市汇总？
- 还需要再观察一下表：regioninfo

A	B	C	D	E	F	G	H	I	J
1	区域表: regioninfo								
2	字段名	字段描述	数据类型	主键	非空	唯一	自增	默认	
3	regionid	地址ID	VARCHAR(4)	Y	Y	N	N	N	
4	parentid	父级ID	VARCHAR(4)	N	Y	N	N	N	
5	regionname	区域名称	VARCHAR(20)	N	Y	N	N	N	
6	regiontype	区域类别 (0国家/1省份/2城市/3区县)	CHAR	N	Y	N	N	N	
7									
8									
9									
10	共有3415个区域								
11									
12									
1	regionid	parentid	regionname	regiontype					
2	1710	204	城步	3					
3	1711	204	双清区	3					
4	1712	204	大祥区	3					
5	1713	204	北塔区	3					
6	1714	204	武冈市	3					
7	1715	204	邵东县	3					
8	1716	204	新邵县	3					
9	1717	204	邵阳县	3					
10	1718	204	隆回县	3					
11	1719	204	洞口县	3					
12	1720	204	绥宁县	3					

自联结把regioninfo看成两张表

首先考虑：orders表中的city=城市表中的regionid
然后再与省份id连接（父级id或者orders表里面的省份id）

```
select 省份表.regionname as 省份,
       城市表.regionname as 城市,
       sum(total_price) as 消费金额,
       sum(total_price)/sum(sum(total_price)) over() as 消费金额占比
from orders left join regioninfo as 城市表
on city=城市表.regionid
left join regioninfo as 省份表
on 城市表.parentid=省份表.regionid
group by 省份表.regionname,城市表.regionname
order by 消费金额占比 desc;
```

	省份 character varying (20)	城市 character varying (20)	消费金额 numeric	消费金额占比 numeric
1	广东	广州	110618.37	0.06884191658495847179
2	湖南	长沙	65051.22	0.04048378818988005554
3	广东	深圳	46180.44	0.02873980152063965152

截图显示前三城市

输出文件保存为：地域分析.csv
可以进一步分析得到地域图



用户留存分析

🔥 用户留存分析

许多用户来了就走，浪费拉新成本
部分行业的部分企业出现获客成本高于客户收益现象
企业在拉新的同时，需要注意对老用户维持

用户留存与留存率

留存用户：某段时间内开始使用某一app,一段时间后仍在使用
这部分用户的留存占比==留存率

- 日留存
- 周留存
- 月留存

留存率是验证用户粘性的关键指标，衡量用户的黏性与忠诚度

根据40-20-20法则，达到40以上为优秀

查询2018年3月的新增用户数，次日留存率，两日留存率，三日留存率

观察数据：注册表customers 登记表：login_log

这个比较简单，只需要在customers表里面找出新增用户，login_log表里面找出登记日期
需要把customers表作为主表，防止有些用户注册以后未访问过

```
SELECT
    created_new,
    COUNT(DISTINCT customers.id) AS 新增用户数,
    SUM(CASE WHEN (login_date - created_new) = 1 THEN 1 ELSE 0 END) AS 次日留存数,
    SUM(CASE WHEN (login_date - created_new) = 3 THEN 1 ELSE 0 END) AS 三日留存数,
    SUM(CASE WHEN (login_date - created_new) = 1 THEN 1 ELSE 0 END) * 1.0 / COUNT(D) AS 次日留存率,
    SUM(CASE WHEN (login_date - created_new) = 3 THEN 1 ELSE 0 END) * 1.0 / COUNT(D) AS 三日留存率
FROM customers
LEFT JOIN login_log ON customers.id = login_log.customer_id
WHERE EXTRACT(YEAR FROM created_new) = 2018
    AND EXTRACT(MONTH FROM created_new) = 3
GROUP BY created_new;
```

文件保存为：用户留存分析.csv

如果用户留存率较低！
怎么办？



用户复购分析

⚠ 用户复购分析

用户对产品重复消费

新用户盈利有限，老用户更有利

复购率

复购指的是一个单位时间内多次购买

查询2017年每月的复购率

观察数据表：orders!

统计一下每个用户的消费次数

```

select 月份,
       sum(是否复购::int) as 复购用户数,
       count(是否复购::int) as 总用户数,
       avg(是否复购::int) as 复购率
from (select
      EXTRACT(month FROM created_at) as 月份,
      customer_id,
      count(*) as 消费次数,
      count(*) > 1 as 是否复购
      from orders
      where EXTRACT(YEAR FROM created_at) = 2017
      group by EXTRACT(month FROM created_at), customer_id) as t
group by 月份;

```

文件已保存--用户复购分析.csv

连续行为天数

🔗 查询2018年3月每个用户的连续下单天数

orders表

区分：2018年3月

分组：用户

求最大连续下单天数(如何判断连续或者分散！)

排序，生成序号，减法

```

select *,
       row_number() over(partition by customer_id order by created_at) as 序号,
       date_sub()
from
      (select distinct customer_id, created_at
      from orders
      where extract(year from created_at) = 2018 and extract(month from created_at) = 3) as t;

```